StabTune 期刊扩展版

新增实验清单与必要性说明

一、使用说明

本清单基于 IJCNN 会议版《StabTune: A Three-Phase Collaborative Framework for Reliable Microservice Kernel Parameter Optimization》整理，目标是扩展为 SCI 三/四区期刊论文。

优先级含义如下：

- **前置（E0）**：修正会议版已有数据和统计问题，必须最先完成。
- **P0**：必做。缺少这些，期刊审稿大概率会要求大修或拒稿。
- **P1**：强烈建议。能显著提高接收概率，并支撑论文中的关键主张。
- **P2**：加分项。有余力再做，三/四区选做 1–2 个即可。

最小可行集：E0–E7 + E8、E9、E13。完成这些后，新增内容通常可以达到期刊对扩展版"至少 30%新内容"的要求。耗时为粗略估计，实际取决于机器数量和并行程度。

二、实验总览

编号	实验	优先级	主要回应的问题	预计耗时	完成
E0	会议版数据与统计复核	前置	表 III 统计量无法复现；多处 CV 与表格数字矛盾	约 1 周	☐
E1	真实微服务基准与多负载水平	P0	负载过低、使用模拟器，内核调参意义存疑	3–4 周（含环境搭建）	☐
E2	主实验重跑与规范化统计报告	P0	10 个 seed 偏少；混合报告掩盖差异	随 E1 同步	☐
E3	补充更强、更新的基线	P0	基线偏旧偏少，缺少调参领域标准方法	2–3 周	☐
E4	风险敏感/稳定性导向基线	P0	无法区分稳定性来自三阶段框架还是 CV 奖励	2 周	☐
E5	完整消融实验（含等预算消融）	P0	原消融只删阶段，且删除后预算变少	2 周	☐

编号	实验	优先级	主要回应的问题	预计耗时	完成
E6	未见负载上的泛化与快速适应	P0	MAML 训练任务即测试任务，“快速适应”从未被验证	2 周	☐
E7	训练成本与端到端调参时间	P0	表 VI 只比推理时间，对 BO 不公平	约 1 周（多数复用日志）	☐
E8	动态负载与在线调参	P1	“实时 auto-tuning”缺少直接证据	2 周	☐
E9	调参过程安全性	P1	只报告收敛结果，未报告探索过程风险	复用日志，约 3 天	☐
E10	参数规模扩展性	P1	10 个参数偏少，可扩展性未知	1–2 周	☐
E11	跨环境迁移	P1	单机、单内核、无干扰，代表性有限	1–2 周	☐
E12	扩展敏感性分析	P1	新奖励的关键参数缺少选择依据	1 周	☐
E13	CV 代理指标有效性	P1	优化的 CV 与评价的 CV 不是同一个量	复用日志，约 2 天	☐
E14	可解释性分析	P2	缺少“学到了什么”的系统洞见	约 1 周	☐
E15	理论分析的实证验证	P2	式(9)与命题 1 缺少实证支撑	复用 E5，约 3 天	☐
E16	与 LLM 调参方法对比	P2	提升时效性	约 1 周	☐
E17	长时间运行稳定性	P2	部署后是否漂移未知	2–3 天（机时）	☐

三、前置工作与 P0 必做实验

E0 会议版数据与统计复核（前置，必做）

为什么需要	期刊审稿人会逐项核对数字。会议版中存在以下问题，不先修正，后续实验再多也可能被判定为数据不可靠： • 表 III 的 t 值和 Cohen's d 无法由表 II 的均值±标准差（n=10）反算。例如 vs Bayesian-Opt，论文 t=2.31，反算约 0.41（p≈0.69）；vs SAC、DDPG、Prior.-DQN 反算后均不显著。可能是用了逐测量点样本（伪重复）。 • 表 II 中 SAC 的 CV：19.52/176.74≈11.04%，表中写 7.23%；Prior.-DQN：26.86/171.45≈15.67%，表中写 11.0%（图 3a 写 15.7%）。 • 正文写 CV=3.06%，表中为 2.45%。 • Prior.-DQN 被定义为 Phase 1-only，但其数据与表 IV 的 Base (Phase 1 only)不同。 • Expert 与 Default 错误率完全相同（2.04±0.37），且 Expert 吞吐低于 Default。 • 测得 QPS（160–184）高于施加负载（λ=150），需说明统计口径。 • kernel.sched_min_granularity_ns 在 Linux 5.13 起已从 sysctl 移至 debugfs，需核实 5.15 上的实际设置方式。
实验设置	• 找回每次运行的原始日志，以“每次运行一个样本”重算均值、std、CV。 • 均值比较：Welch t 检验 + Holm 多重比较校正；效应量用 pooled Cohen's d。 • 方差比较：Levene 或 Brown-Forsythe 检验（这是 StabTune 真正显著的地方：与 BO 的方差比约 22.8，p<0.001）。 • CV 的 bootstrap 95%置信区间（10,000 次重采样）。 • 写成统计脚本并随代码开源，后续所有实验复用。
记录指标	修正后的 QPS、延迟、错误率、CV；t、p（校正后）、d；方差检验统计量；CV 置信区间。
论文产出	修正后的表 II、表 III；新增“方差齐性检验”表；可复现的统计脚本。
预期结论	核心主张调整为：吞吐量与最强基线相当或略优，同时跨运行方差显著降低。

E1 真实微服务基准与多负载水平（P0）

为什么需要	当前三种负载只有 150/100/50 QPS，对 24 核+25GbE 服务器几乎是空载，somaxconn、backlog、TCP 缓冲区等网络参数在这种负载下作用有限。系统方向审稿人很可能质疑“调参是否真的有意义”。文中引用了 DeathStarBench，但实际使用的是自建模拟器，可信度

	打折。
实验设置	• 应用：DeathStarBench 的 SocialNetwork 和 HotelReservation（可选 MediaMicroservices）。 • 压测工具：wrk2 开环压测（恒定请求速率，避免 coordinated omission，尾延迟测量更准确）。 • 先逐步加压，测出每个应用在 P99 不超过 SLO 时的最大可持续吞吐（容量），再在容量的 30%/60%/90%三个负载水平分别运行。 • 请求分布：均匀、读多写少、突发三种。 • 保持原协议：30s 预热 + 5min 测量；试验间重置参数、清缓存、重启服务。 • 注意：开环压测下吞吐等于施加速率（未饱和时），主指标建议改为“SLO 约束下的最大可持续吞吐”或“固定速率下的 P99 延迟”。
记录指标	最大可持续吞吐、P50/P95/P99 延迟、错误率、CPU/内存利用率、跨运行 CV。
论文产出	新的主结果表（应用 × 负载水平），替代或补充原表 II；容量测定曲线图。
预期结论	高负载（60%、90%）下调参收益明显大于低负载，这本身就是“内核调参有意义”的证据。

E2 主实验重跑与规范化统计报告（P0）

为什么需要	10 个 seed 对 RL 方差估计偏少，RL 可复现性文献（Henderson et al. 2018；Agarwal et al. 2021）建议更多 seed 并报告置信区间。既然论文卖点是稳定性，稳定性的统计证据必须更扎实。另外原表把三种 workload 混在一起报告，掩盖了不同负载下的差异。
实验设置	• 所有方法至少 20 个 seed（建议 30 个），统一交互预算。 • 按应用、负载水平分开报告，再给出总体汇总。 • 使用 rliable 库：IQM（四分位均值）+ 分层 bootstrap 置信区间、性能分布曲线、probability of improvement。 • 同时保留 Welch t + Holm 校正、Levene 方差检验、CV 的 bootstrap 置信区间。
记录指标	每个 run 的最终 QPS、P99、错误率；跨 run 的均值、IQM、std、CV 及其置信区间。
论文产出	主结果表 + 带置信区间的性能分布图 + 方差检验表。

E3 补充更强、更新的基线（P0）

为什么需要	现有基线（DDPG、SAC、DQN、普通 BO）较老。系统调参领域的标准基线是 OtterTune 风格的 GP-BO、SMAC、TPE、HEBO 等；没有随机搜索则无法说明问题的难度。“baselines are outdated”是期刊审稿最常见的意见之一。
实验设置	• BO 类：SMAC3、Optuna-TPE、HEBO、GP-BO（EI 采集函数，OtterTune 风格）。 • RL 类：PPO、Double + Dueling DQN、CDBTune（DDPG）。 • 下界：Random Search。 • 所有方法使用相同的 knob 集合、安全范围、交互预算，预算定义写入论文。
记录指标	同 E2。
论文产出	主结果表新增行；相关工作部分同步补充这些方法。

E4 风险敏感/稳定性导向基线（P0）

为什么需要	论文的核心贡献是稳定性。审稿人一定会问：稳定性提升究竟来自三阶段框架，还是只来自 CV 惩罚奖励？如果单阶段 DQN 加上 CV 奖励就能达到相近的 CV，框架的贡献就站不住。因此必须与“直接优化风险或方差”的 RL 方法对比。
实验设置	• 单阶段 PER-DQN + 相同 CV 奖励（相同λ、τ），预算等于 StabTune 三个阶段的总预算。 • Mean-variance 目标的 PPO。 • CVaR 目标（QR-DQN 取下分位，或 CVaR-PPO）。 • 简单方差削减基线：多 seed 集成/策略平均。
记录指标	QPS、CV 及其置信区间；训练总成本。
论文产出	稳定性对比表 + QPS–CV 散点图（标出 Pareto 前沿）。
预期结论	StabTune 在相同预算下 CV 更低或吞吐更高。如果结果不如预期，需要相应调整贡献表述。

E5 完整消融实验（含等预算消融）（P0）

为什么需要	原表 IV 只做了逐阶段删除，而且删除阶段后总交互预算也随之减少，无法区分“这个阶段有用”还是“只是预算更多”。每个设计选择都需要独立证据。

实验设置	• V1：λ=0，去掉 CV 奖励。 • V2：PER 换成均匀经验回放。 • V3：MAML 换成多任务联合训练（相同数据和步数）。 • V4：MAML 换成 Reptile 或 FOMAML。 • V5：BO 换成随机搜索（同样 20 次）。 • V6：BO 换成固定默认超参数。 • V7：等预算删除——删去某阶段，把它的交互预算补给其余阶段。 • V8：调换阶段顺序（如 2→1→3）。 • V9：Phase 1 只传参数、不传 replay 摘要（验证Δtransfer）。
记录指标	QPS、CV、训练成本。
论文产出	扩展后的表 IV。

E6 未见负载上的泛化与快速适应（P0）

为什么需要	论文声称 MAML 带来对新负载的快速适应，但 Phase 2 的训练任务就是测试用的三种负载，快速适应能力从未被检验。这是方法论上的明显漏洞，审稿人很容易发现。
实验设置	• Leave-one-workload-out（3 折）：两种负载做元训练，第三种做测试。 • 另构造 2–3 种新负载（不同读写比、请求大小、突发强度）；用 DeathStarBench 中另一个应用做跨应用测试。 • 对比：StabTune 元初始化 + k 步适应、从零训练、多任务预训练 + 微调、直接迁移不适应。 • k ∈ {0, 1, 3, 5, 10, 20}。
记录指标	适应曲线；达到最优性能 90%所需步数；适应后的 CV。
论文产出	适应曲线图 + 适应效率表。

E7 训练成本与端到端调参时间（P0）

为什么需要	BO 离线调参完成后输出的是静态配置，部署时没有推理开销，只比推理时间对 BO 不公平，容易被指出。另外离散±步长动作意味着到达目标配置需要多步，每步都要测量数秒到数分钟，2.1ms 推理并不是瓶颈。需要报告真实的总成本。
实验设置	• 记录各阶段 wall-clock 时间、环境交互次数、GPU/CPU 时间。

	• 所有方法的 time-to-target 曲线（横轴 wall-clock，纵轴当前最优性能）。 • 部署阶段从负载变化到重新收敛的实际时间（与 E8 联动）。
记录指标	训练总时长、交互次数、达到目标性能所需时间。
论文产出	成本对比表 + time-to-target 图；重写“Why DRL over BO”一节，把论点从推理延迟改为在线适应能力。

四、P1 强烈建议实验

E8 动态负载与在线调参（P1）

为什么需要	结论中强调 StabTune 能在流量突发时实时调参，但所有实验都是静态负载，这一主张没有直接证据。这也是支撑 DRL 相对 BO 优势的关键实验。
实验设置	• 负载模式阶跃切换（如 API Gateway → DB Proxy）。 • 真实 trace 回放（Alibaba 微服务 trace 或 Azure trace，按比例缩放）。 • 突发流量注入。 • 对比：StabTune 在线调参、BO 定期重调（每 T 分钟）、静态最优配置、Default。
记录指标	吞吐和 P99 的时间序列；切换后恢复时间；切换期间 SLO 违约率；累计性能损失。
论文产出	时间序列图 + 汇总表。

E9 调参过程安全性（P1）

为什么需要	生产环境关心的不仅是最终配置，还有探索过程中会不会产生劣化配置。OnlineTune、ResTune 等工作都把安全性作为核心评价指标，目前论文没有这部分。
实验设置	• 在训练和在线调参全过程中记录每一次被评估配置的性能。
记录指标	低于 Default 性能的配置比例、SLO 违约次数、最差性能、累计 regret。
论文产出	安全性对比表 + 训练过程性能分布图。

E10 参数规模扩展性（P1）

为什么需要	10 个参数偏少，审稿人会质疑方法能否扩展；离散动作空间随参数数量线性增长，需要验

	证性能和成本如何变化。
实验设置	• 参数数量 10 → 20 → 30，新增如 net.core.rmem_max/wmem_max、net.ipv4.tcp_congestion_control、vm.dirty_ratio、vm.dirty_background_ratio、net.ipv4.tcp_slow_start_after_idle、net.core.busy_poll 等。
记录指标	不同维度下的 QPS、CV、训练成本。
论文产出	扩展性曲线图。

E11 跨环境迁移（P1）

为什么需要	目前只在一台无共置租户的服务器、一个内核版本上实验，代表性有限。
实验设置	• 另一台不同配置的机器。 • 内核 6.x（注意 6.6 起采用 EEVDF 调度器，部分调度参数有变化）。 • 多节点 Kubernetes 部署。 • 同机干扰：用 stress-ng 等注入 CPU、内存带宽、网络干扰。
记录指标	各环境下的 QPS、P99、CV；直接迁移与重新适应的对比。
论文产出	迁移结果表。

E12 扩展敏感性分析（P1）

为什么需要	原文只分析了λ和 Phase 1 episode 数。τ_CV、窗口 W 等是新提出奖励的关键参数，必须说明取值依据和鲁棒性。
实验设置	• τ_CV、W、w1–w3、MAML 内循环步数 K、BO 迭代次数、网络规模。 • 测量噪声注入：对观测 QPS 加高斯噪声（σ = 0/2/5/10%）。
记录指标	QPS、CV。
论文产出	敏感性图组。

E13 CV 代理指标有效性（P1）

为什么需要	奖励中的 CV 是单次运行窗口内的时间 CV，Phase 3 的目标是奖励的 CV，而评价指标是跨运行 CV。三者不同，论文需要证明优化前者确实能降低后者，否则方法与评价之间存

	在逻辑断层。这个实验几乎不需要额外运行，性价比很高。
实验设置	• 对所有方法、所有 seed，计算训练末期的窗口内 CV 与最终跨运行 CV。 • 比较不同 W 下的相关性。
记录指标	Spearman 相关系数。
论文产出	散点图 + 相关系数表。

五、P2 加分实验

E14 可解释性分析（P2）

为什么需要	系统类期刊重视方法学到了什么，这类分析能给运维人员提供可借鉴的经验，也能增加论文篇幅的实质内容。
实验设置	• fANOVA 或 SHAP 分析参数重要性。 • 各负载下最终配置与 Default 的对比表。 • 典型策略轨迹可视化。
记录指标	参数重要性排序、配置差异。
论文产出	重要性柱状图 + 配置对比表。

E15 理论分析的实证验证（P2）

为什么需要	式(9)的分解和命题 1 的“自调节”解释目前只是论述，没有实验支撑。审稿人可能认为理论部分是装饰。
实验设置	• 用 E5 中的 V7、V9 结果估计Δtransfer 和Δmeta。 • 训练中记录命题 1 两项梯度的范数比例随时间的变化。
记录指标	Δtransfer、Δmeta 估计值；梯度项比例曲线。
论文产出	分解表 + 梯度动态图。

E16 与 LLM 调参方法对比（P2）

为什么需要	近年 AutoOS、GPTuner 等基于大语言模型的调参方法兴起，加入对比能提升论文时效性。
实验设置	• 让 LLM 基于参数文档和观测结果迭代给出配置推荐，给定与其他方法相同的交互次数。
记录指标	QPS、CV、调参成本。
论文产出	主表新增一行或单独小节。

E17 长时间运行稳定性（P2）

为什么需要	验证部署后性能是否随时间漂移，进一步支撑“生产可靠性”的主张。
实验设置	• 24 小时连续运行，负载按日周期变化。
记录指标	性能和配置随时间的变化。
论文产出	时间序列图。

六、通用实验规范

以下规范适用于所有实验，写进论文的实验设置部分，也是审稿人判断结果可信度的依据：

- **统一预算**：所有方法使用相同的 knob 集合、安全范围和环境交互次数，预算的具体定义（按 knob 评估次数还是 episode）写进论文。
- **seed 数量**：每个方法至少 20 个 seed；统计检验以“每次运行一个样本”为单位，避免伪重复。
- **试验独立性**：每次试验之间重置内核参数、清空缓存、重启服务容器。
- **统计方法**：均值用 Welch t 检验 + Holm 校正；方差用 Levene 或 Brown-Forsythe 检验；CV 报告 bootstrap 95%置信区间；汇总用 IQM + 置信区间。
- **日志与开源**：记录每一步的配置、指标和时间戳；原始日志、脚本和配置随论文开源，期刊审稿中是明显加分项。
- **如实报告代价**：StabTune 的平均延迟、错误率和 P99 在会议版中均为最高，新实验中应如实报告，并用 QPS–延迟 Pareto 图讨论这一权衡。